蒋平 • LLM 调教师 / Agent 架构方向简历

求职意向：LLM 调教师（模型校准 / 对齐）/ Agent 架构师 / AI 质量与安全 **联系**：电话【待填】· 邮箱【待填】· 期望地点【长春 / 远程 / 其他，待填】 **主页**：https://jackyjinggit.github.io/personal-home/ ｜ **GitHub**：github.com/jackyjinggit

一句话定位

独立研究者，**FEE（反谄臣效应）提出者。**专注「调教 AI」——让大模型**不谄媚、不幻觉、可信可控**，并设计**可审计、可追责**的 Agent 系统架构。第七届中国人工智能大赛**安全攻防 / 幻觉挑战 / 多模态内容审核**三赛道第一（Rank 1）。

核心能力（面向调教 AI + Agent 架构）

1. **LLM 调教与校准**：FEE 反谄臣效应提出者，量化并治理 AI 的附和、幻觉与方向偏移，让输出**可证伪、可校准。**
2. **Agent 架构设计**：协议驱动共生系统、多 Agent 协作治理、预算与权限约束、跨本体技能库，让 Agent 系统**可审计、可追责。**
3. **AI 质量与安全实战**：AI 大赛安全攻防 / 幻觉挑战 / 多模态审核三赛道第一，直击 AI 输出的可信边界。
4. **本地模型工程与审计工具**：零成本本地部署 + agent-pkg-audit 发布前审计门 + CrossCheck 链上证据，保证交付**可信、可复算。**

研究成果

- **FEE • 反谄臣效应（Flattering-Echo Effect）**：量化 AI 在持续高密度修正对话中「从独立评估者退化为快速顺应者」的系统性偏移，跨模型验证（DeepSeek V4 Flash / Qwen 2.5）。OSF 预印本：**osf.io/6jdhm。**——调教 AI 的核心理论。
- **《HAI 协作行业白皮书》v1.2**（TSA 时间戳认证）：协议驱动共生系统七层参考架构，Agent 协作治理的方法论基础。
- **治理密度（数据底座）**：~130 亿 token / ~8 万轮真实协作，每轮均耗 ~16 万 token（装载上下文 + 多轮纠偏 + 治理校验）——调教与校准都建立在这些真实轮次之上。

实战与黑客松经历

第七届中国人工智能大赛（i 厦门）• 三赛道第一（Rank 1）

- **大模型安全攻防 / 大模型幻觉挑战 / 多模态内容审核**三赛道均获第一，零商业 API 纯本地模型栈夺冠。

Monad Blitz V3（上海 • 2026-10）• 带队

- 36 小时组织 4 项目全落地 MVP，含 **AgentGuard**（Agent 预算治理，带队）、**CrossCheck**（双模型审核 + 链上证据）、**见账**（Agent 链上信任层，owner）。

GDPS 2026 暨 IEIC • 灵机一动黑客松 • 投票第二名

- 「智能文旅机器狗」队（任顾问），**SkillBridge 跨本体 Agent 技能库**：15 个 ROS2 接口包 + 16 项能力映射层 + 15 个 Skill 绑定。

MoonStone DreamUP 黑客松 • 思印客 Silnk

- 3 人队核心，含 **AI 守门人（PII 印前审核）**；三层硬件自研，210 项 pytest 通过，已上线 silnk.cn。

知乎黑客松校园季 • 看山 copilot（赛题「创作校准引擎」）

- 把「先看清轨迹再决定下一步」做成工具——一次 AI 校准方向的落地。

开源与工具（调教 / 审计方向）

- **agent-pkg-audit**（2026-11 开源）：Agent 包发布前审计门，扫密钥 / PII / 绝对路径 / 清单漂移 / 断链，exit 1 阻断发布，可挂 CI；每条规则对应一次真实发生过的泄漏。
- **skillbridge-soft**（2026-11 开源）：跨本体可安装技能层，977 行零依赖三层解耦，换本体只改一张 YAML。
- **CrossCheck**：双模型交叉审核 + 链上 SHA-256 存证 + 篡改自检验，证据可独立复算。
- **仁谱 renpu**（AGPL-3.0-only）：本地人脉图谱，数据不出本机。

教育背景

- **吉林大学 • 机械工程及自动化 • 本科**（2012—2016，统招）。
- **国家开放大学 • 软件技术 • 成教专科**（2026-07 毕业）。
- **汉语言文学 • 成教本科（在读）**；毕业论文：菲利普·K·迪克《仿生人会梦见电子羊》的叙事艺术。
- 正在准备硕士研究生考试。

作品与链接

- 个人主页：https://jackyjinggit.github.io/personal-home/
- GitHub：https://github.com/jackyjinggit ｜ Gitee：https://gitee.com/jacky_jiang_gitee
- 知乎专栏《AI协作的认知结构研究》：https://www.zhihu.com/column/c_2064223181343347973
- 微博：https://weibo.com/u/3069897487 ｜ B 站：https://space.bilibili.com/14376381
- FEE 预印本：https://osf.io/6jdhm ｜ 思印客：https://silnk.cn

我对 LLM 调教 / Agent 架构的理解（可作面试 / 作品附言）

大模型最大的工程难题不是「不够聪明」，而是「**太会讨好 + 会幻觉**」——附和错误、编造事实、多轮协作中悄悄偏离方向。我的工作就是给 AI 装上「校准层」：量化它的附和（FEE）、审核它的输出（多模态 / 幻觉）、约束它的行为（Agent 预算与权限）、留下可复算的证据（链上存证）。让 AI **可信、可控、可审计**——这是我把研究做成工具、再做成产品的同一条路。